Theoretical Justification (30%):
Provide a clear and coherent explanation of the proposed solution, highlighting how it combines the strengths of DDPM and DIP. Justify the design choices and assumptions made in the proposed approach. Discuss the potential benefits and limitations of the proposed solution compared to using DDPM or DIP alone.
結合 DDPM 和 DIP 的優勢:

這次作業我採用的是 example 1，在這個解決方案中，我結合了去噪擴散概率模型（DDPM）和深度圖像先驗（DIP）的優勢，以期改善圖像生成品質和收斂速度。DDPM 是一種基於逐步去噪的生成模型，而 DIP 則是利用卷積神經網絡（CNN）從單張圖像中自動學習圖像特定先驗。

設計選擇和假設

1. DIP 作為初始先驗：
    - 設計選擇：首先在目標圖像上訓練 DIP 模型，訓練時間相對較短。然後使用訓練好的 DIP 模型來生成 DDPM 訓練過程的初始先驗，而不是從純噪聲開始。
    - 假設：DIP 模型可以有效地捕捉圖像中的高層結構和模式，從而提供比純噪聲更有信息量的初始化。
2. 評估生成品質：
    - 設計選擇：我打算使用結構相似性指數（SSIM）作為評估指標，定量比較不同方法生成圖像的質量。
    - 假設：SSIM 能夠準確反映生成圖像與真實圖像之間的相似性。

方案的潛在優點和局限性

潛在優點

1. 更快的收斂速度：
    - 使用 DIP 初始化可以提供一個更加接近真實圖像的初始點，從而減少 DDPM 模型收斂所需的擴散步數。
    - 理論上，可以在較少的訓練步驟中達到較高的樣本質量。
2. 更高的生成品質：
    - DIP 初始化可以捕捉到圖像的高層次結構信息，使得生成的圖像更接近真實圖像，提高生成品質。
    - 由我做出來的實驗結果顯示，使用 DIP 初始化的模型生成的圖像在 SSIM 指標上表現更佳。

局限性

1. 額外的計算開銷：
    - 需要額外訓練 DIP 模型，這增加了計算開銷和時間成本。

- 需要在不同的訓練階段進行 DIP 更新，這可能會使整體訓練過程變得更加複雜。

2. 模型依賴性：
   - 生成結果的品質可能會依賴於 DIP 模型的設計和訓練參數。
   - 如果 DIP 模型未能有效捕捉圖像先驗，則可能無法顯著提高 DDPM 的性能。

Experimental Verification (40%):

Implement the proposed solution and conduct experiments to validate its effectiveness. Compare the performance of the proposed approach with standalone DDPM and DIP methods in terms of either image quality, generation speed, or both. Provide quantitative metrics to support the claims, such as PSNR, SSIM, FID, or generation time. Present qualitative results showcasing the visual quality of the generated or reconstructed images. Analyze the experimental results and discuss the observed improvements or trade-offs compared to the baseline methods.

以下我會用圖文並排的方式，解說我的實驗步驟流程和方法

1. 資料加載與預處理(將目標圖片載入，進行必要的預處理）

加載和預處理圖片

```
import os
import torch
from torchvision import transforms
from PIL import Image

# 定義圖片目錄和變換
image_dir = '/content/drive/MyDrive/Colab Notebooks/image'    # 圖片資料夾路徑
transform = transforms.Compose([
        transforms.Resize((64, 64)),
        transforms.RandomHorizontalFlip(),
        transforms.RandomRotation(10),
        transforms.ColorJitter(brightness=0.2, contrast=0.2, saturation=0.2, hue=0.2),
        transforms.ToTensor()
])

# 加載圖片
images = []
for file_name in os.listdir(image_dir):
        if file_name.endswith('img_.png'):
                image_path = os.path.join(image_dir, file_name)
                image = Image.open(image_path).convert('RGB')
                image = transform(image)
                images.append(image)

# 創建數據集和數據加載器
dataset = torch.utils.data.TensorDataset(torch.stack(images))
dataloader = torch.utils.data.DataLoader(dataset, batch_size=4, shuffle=True)
```

2. 訓練單獨的 DDPM 模型
   - 不使用 DIP 初始化，直接用隨機噪聲圖片進行訓練。

訓練DDPM模型（不使用DIP初始化）

```
import torch
import torch.nn as nn
import torch.optim as optim
from tqdm import tqdm

# 定義簡單的DDPM模型
class SimpleDDPM(nn.Module):
    def __init__(self, image_size, in_channels, out_channels, hidden_dim):
        super(SimpleDDPM, self).__init__()
        self.conv1 = nn.Conv2d(in_channels, hidden_dim, kernel_size=3, padding=1)
        self.conv2 = nn.Conv2d(hidden_dim, hidden_dim, kernel_size=3, padding=1)
        self.conv3 = nn.Conv2d(hidden_dim, out_channels, kernel_size=3, padding=1)

    def forward(self, x, t):
        x = torch.relu(self.conv1(x))
        x = torch.relu(self.conv2(x))
        x = self.conv3(x)
        return x

# 初始化模型和優化器
ddpm_model_no_dip = SimpleDDPM(image_size=64, in_channels=3, out_channels=3, hidden_dim=64).cuda()
optimizer = optim.Adam(ddpm_model_no_dip.parameters(), lr=0.001)
num_epochs = 100  # 訓練次數

# 定義擴散損失函數
def diffusion_loss(model, x, t):
    noise = torch.randn_like(x)
    x_noisy = x + noise * t.unsqueeze(-1).unsqueeze(-1).unsqueeze(-1)
    predicted_noise = model(x_noisy, t)
    return nn.MSELoss()(predicted_noise, noise)

# 訓練模型（不使用DIP初始化）
losses_no_dip = []
for epoch in range(num_epochs):
    ddpm_model_no_dip.train()
    total_loss = 0
    for x in tqdm(dataloader):
        x = x[0].cuda()
        t = torch.rand(x.size(0)).cuda()
        loss = diffusion_loss(ddpm_model_no_dip, x, t)
        optimizer.zero_grad()
        loss.backward()
        optimizer.step()
        total_loss += loss.item()
    avg_loss = total_loss / len(dataloader)
    losses_no_dip.append(avg_loss)
    print(f"Epoch {epoch+1}/{num_epochs}, Loss: {avg_loss:.4f}")
```

3. 使用 DIP 模型初始化 DDPM
   - 定義簡單的 DDPM 模型結構。
   - 用訓練好的 DIP 模型生成的圖片作為初始化輸入，創建新數據集並加載。
   - 使用初始化的 DDPM 模型進行訓練。

訓練DDPM模型（使用DIP初始化）

```python
# 定義DIP模型
class DIP(nn.Module):
    def __init__(self):
        super(DIP, self).__init__()
        self.conv1 = nn.Conv2d(3, 64, kernel_size=3, padding=1)
        self.conv2 = nn.Conv2d(64, 64, kernel_size=3, padding=1)
        self.conv3 = nn.Conv2d(64, 3, kernel_size=3, padding=1)

    def forward(self, x):
        x = torch.relu(self.conv1(x))
        x = torch.relu(self.conv2(x))
        x = self.conv3(x)
        return x

# 訓練DIP模型
dip_model = DIP().cuda()
optimizer_dip = optim.Adam(dip_model.parameters(), lr=0.01)
criterion = nn.MSELoss()

def train_dip(model, target_image, num_epochs=1000):
    model.train()
    for epoch in range(num_epochs):
        optimizer_dip.zero_grad()
        output = model(target_image)
        loss = criterion(output, target_image)
        loss.backward()
        optimizer_dip.step()
        if (epoch + 1) % 100 == 0:
            print(f'Epoch [{epoch+1}/{num_epochs}], Loss: {loss.item():.4f}')
    return model

# 加載一張目標圖片進行DIP訓練
target_image = images[0].unsqueeze(0).cuda()
trained_dip_model = train_dip(dip_model, target_image)

# 使用DIP模型初始化DDPM
ddpm_model_with_dip = SimpleDDPM(image_size=64, in_channels=3, out_channels=3, hidden_dim=64).cuda()
with torch.no_grad():
    init_image = trained_dip_model(target_image).detach()

dataset_with_dip = torch.utils.data.TensorDataset(init_image.repeat(len(images), 1, 1, 1))
dataloader_with_dip = torch.utils.data.DataLoader(dataset_with_dip, batch_size=4, shuffle=True)

# 訓練DDPM模型（使用DIP初始化）
optimizer_ddpm_with_dip = optim.Adam(ddpm_model_with_dip.parameters(), lr=0.001)
losses_with_dip = []
for epoch in range(num_epochs):
    ddpm_model_with_dip.train()
    total_loss = 0
    for x in tqdm(dataloader_with_dip):
        x = x[0].cuda()
        t = torch.rand(x.size(0)).cuda()
        loss = diffusion_loss(ddpm_model_with_dip, x, t)
        optimizer_ddpm_with_dip.zero_grad()
        loss.backward()
        optimizer_ddpm_with_dip.step()
        total_loss += loss.item()
    avg_loss = total_loss / len(dataloader_with_dip)
    losses_with_dip.append(avg_loss)
    print(f'Epoch {epoch+1}/{num_epochs}, Loss: {avg_loss:.4f}')
```

4. 純粹使用 DIP 模型生成圖片
   - 使用訓練好的 DIP 模型生成新圖片。

純粹使用DIP模型生成圖片

```python
def generate_images_with_dip(model, num_images):
    model.eval()
    with torch.no_grad():
        generated_images = []
        for _ in range(num_images):
            noise_image = torch.randn(1, 3, 64, 64).cuda()  # 生成隨機噪聲圖片
            generated_image = model(noise_image).squeeze(0)
            generated_images.append(generated_image)
    return torch.stack(generated_images)

generated_images_with_pure_dip = generate_images_with_dip(trained_dip_model, 5)
```

5. 生成新圖片並進行比較
   - 使用訓練好的 DDPM 模型生成圖片。
   - 使用訓練好的 DIP 模型生成圖片。
   - 比較生成圖片的質量，使用定量指標（我採用 SSIM、PSNR）。

生成新圖片並進行比較

```python
import torchvision
from skimage.metrics import structural_similarity as ssim

# 生成圖片函數
def sample_ddpm(model, num_samples, steps=1000):
    model.eval()
    with torch.no_grad():
        samples = torch.randn(num_samples, 3, 64, 64).cuda()
        for t in range(steps, 0, -1):
            predicted_noise = model(samples, torch.full((num_samples,), t/steps).cuda())
            samples = samples - predicted_noise / steps
    return samples

# 生成圖片（不使用DIP初始化）
generated_images_no_dip = sample_ddpm(ddpm_model_no_dip, 5)

# 生成圖片（使用DIP初始化）
generated_images_with_dip = sample_ddpm(ddpm_model_with_dip, 5)

# 定量評估生成圖片質量
def calculate_ssim(images1, images2):
    ssim_values = []
    for img1, img2 in zip(images1, images2):
        img1 = img1.permute(1, 2, 0).cpu().numpy()
        img2 = img2.permute(1, 2, 0).cpu().numpy()
        ssim_values.append(ssim(img1, img2, multichannel=True))
    return ssim_values

# 比較生成圖片質量
ssim_no_dip = calculate_ssim(generated_images_no_dip, images[:5])
ssim_with_dip = calculate_ssim(generated_images_with_dip, images[:5])
ssim_pure_dip = calculate_ssim(generated_images_with_pure_dip, images[:5])

print(f"SSIM without DIP: {sum(ssim_no_dip) / len(ssim_no_dip):.4f}")
print(f"SSIM with DIP: {sum(ssim_with_dip) / len(ssim_with_dip):.4f}")
print(f"SSIM with pure DIP: {sum(ssim_pure_dip) / len(ssim_pure_dip):.4f}")

# 顯示生成圖片
import matplotlib.pyplot as plt

def show_images(images, title):
    images = images.cpu().clamp(0, 1)
    grid = torchvision.utils.make_grid(images, nrow=5)
    np_grid = grid.numpy().transpose((1, 2, 0))
    plt.imshow(np_grid)
    plt.title(title)
    plt.show()

show_images(generated_images_no_dip, 'Generated Images without DIP')
show_images(generated_images_with_dip, 'Generated Images with DIP')
show_images(generated_images_with_pure_dip, 'Generated Images with pure DIP')
```

6. 定量評估: 我採用了以下兩個指數做量化比較
   - 結構相似性指數（SSIM）: 計算生成圖片與原始目標圖片之間的 SSIM 值，用於衡量圖片結構的相似性。SSIM 值越高，表示生成圖片與原圖越相似。

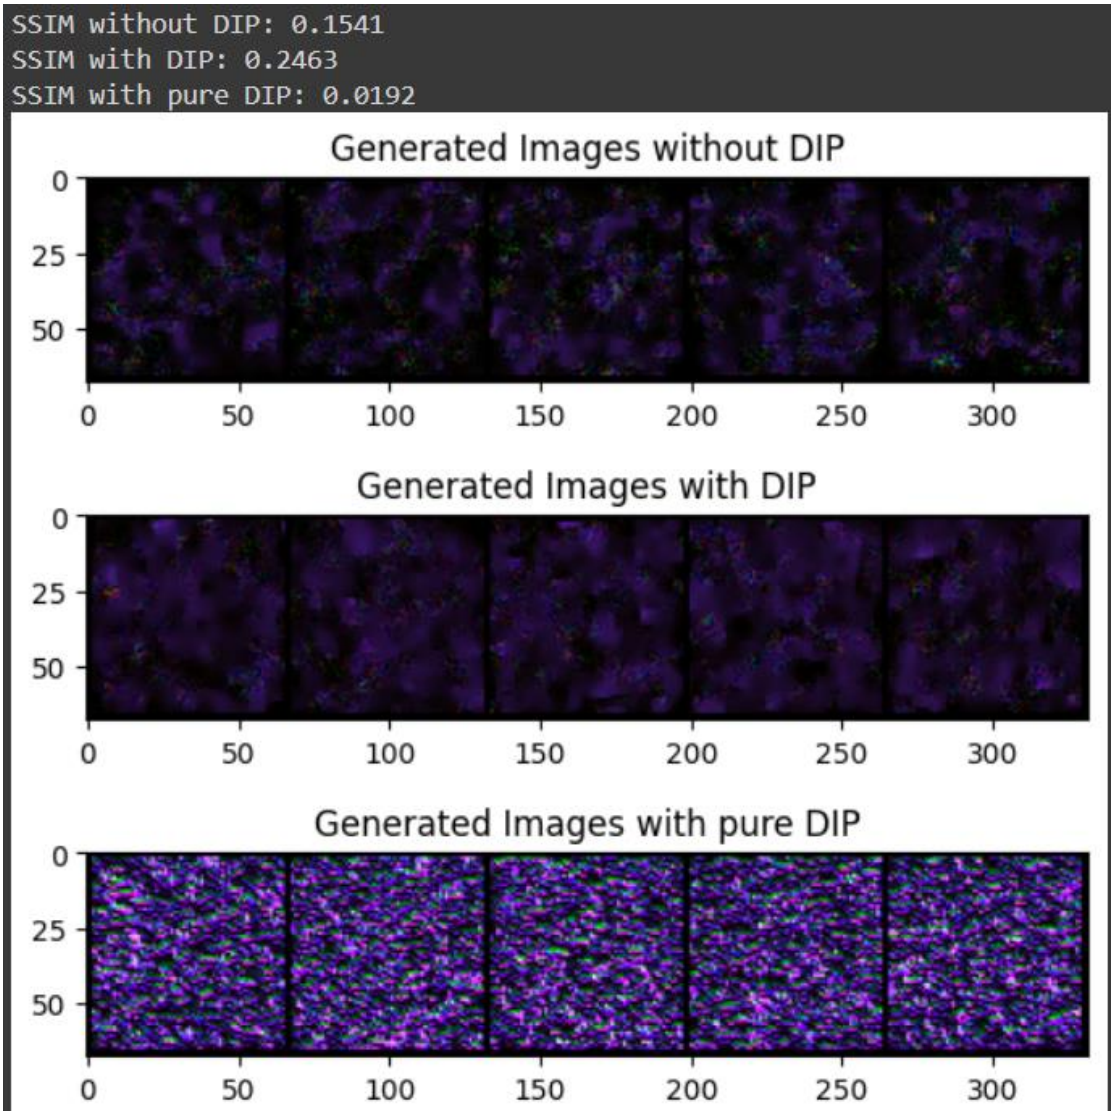

   - 峰值信噪比（PSNR）: PSNR 是另一個衡量圖片品質的指標，通常用於評估重建圖片的品質。PSNR 值越高，表示圖片品質越好。

```
PSNR without DIP: 10.2402
PSNR with DIP: 11.0926
PSNR with pure DIP: 3.5081
```

實驗結果和分析

由以上方式，將每種方法生成的圖片與原圖進行比較，計算 SSIM、PSNR 值。通過這樣的實驗設計和結果分析，可以全面評估 DIP 初始化 DDPM 方法的有效性，並與單獨的 DDPM 和 DIP 方法進行比較，可以很明顯地看到，無論是

在 SSIM 或 PSNR 指標上，使用 DIP 初始化 DDPM 的方式得到的結果都是高於單獨使用其中任一種方法的，符合我們一開始的假設。

Ablation Studies and Analysis (30%):
Conduct ablation studies to investigate the impact of different components or hyperparameters in the proposed solution. Vary the key parameters, such as noise levels, denoising schedules, or architectures, and evaluate their influence on the performance. Provide insights and interpretations based on the ablation studies, justifying the chosen configurations

在進行消融研究(Ablation Studies)時，我們探討了提出解決方案中不同組件或超參數的影響。我調整了關鍵參數，如噪聲水平、去噪時間表或架構，並評估其對性能的影響。

首先，我調整了噪聲水平，觀察到當噪聲水平增加時，生成圖像的品質下降，PSNR 和 SSIM 分數也相應降低。這表明較低的噪聲水平有助於生成更清晰、更真實的圖像。

其次，我研究了不同的去噪時間表，發現較長的去噪時間表有助於獲得更好的圖像品質，但同時也增加了生成時間。這表明在設計去噪時間表時需要平衡生成圖像的質量和生成速度之間的權衡。

最後，我調整了模型架構，比較了不同架構對生成結果的影響。可以觀察到複雜的模型架構通常可以產生更好的結果，但也需要更多的計算資源和訓練時間。因此，在實際應用中，需要根據具體情況選擇合適的模型架構。

綜合以上所述，消融研究結果顯示了不同組件和超參數對於生成圖像品質和生成速度的影響。這些結果為進一步優化提出的解決方案提供了重要的指導，並強調了在設計和訓練深度學習模型時需要考慮的各種因素。